编译原理 词法分析实验

19335286 郑有为

一、实验说明

词法分析程序实验：

1. 实验目的：通过扩充已有的样例语言TINY语言的词法分析程序，为扩展TINY语言TINY＋构造词法分析程序，从而掌握词法分析程序的构造方法
2. 实验内容：了解样例语言TINY及TINY编译器的实现，了解扩展TINY语言TINY＋，用C语言在已有的TINY词法分析器基础上扩展，构造TINY＋的词法分析程序。
3. 实验要求：将TINY＋源程序翻译成对应的TOKEN序列，并能检查一定的词法错误。

提交源程序和可运行程序。

二、TINY+词法定义

来源：同学在作业连接下分享的文件

2.1 关键字

关键字包括：（小写）

`or`, `and`, `int`, `bool`, `char`, `while`, `do`, `true`, `false`

`if`, `then`, `else`, `end`, `repeat`, `until`, `read`, `write`

2.2 操作符

操作符包括：

`>`, `<=`, `>=`, `<`, `=`

`,`, `'`, `{`, `}`, `;`, `:=`

`(`,`)`, `+`, `-`, `*`, `/`

2.3 分隔符

空格符包括：` `, `\t`, `\n`，在词法分析后不被保留。

2.4 其他符号

其他符号有四种，他们的正则定义如下：

- 标识符 `ID`：`letter(letter|digit)*`
- 数字 `NUM`：`digit digit*`
- 字符串 `STRING`：`'any char except ' '`（不能跨行定义）
- 注释：`{...}`（用花括号标注，可以跨行定义）

三、程序说明

3.1 编译运行

- Windows下运行

```
gcc la.c -o la.exe
a.exe
```

- 测试文件位于`\test`文件夹

3.2 数据定义

- 程序中定义的 TOKEN 类型

```
    // Keyword tokens                   // |-18 Keywords-----------|
    KEY_OR, KEY_AND, KEY_NOT,           // | or    | and   | not   |
    KEY_INT, KEY_BOOL, KEY_CHAR,        // | int   | bool  | char  |
    KEY_WHILE, KEY_DO,                  // | while | do    |       |
    KEY_IF, KEY_THEN, KEY_ELSE,         // | if    | then  | else  |
    KEY_END, KEY_REPEAT, KEY_UNTIL,     // | end   | repeat| until |
    KEY_READ, KEY_WRITE,                // | read  | write |       |
    KEY_TRUE, KEY_FALSE,                // | true  | false |       |

    // Operator tokens                  // |-17 Operators-|
    OP_G, OP_L, OP_ASSIGN,              // | >  | <  | := |
```

```
    OP_GE, OP_LE, OP_EQ,                // | >= | <= | =  |
    OP_COMMA, OP_QUOTA, OP_SEMI,        // | ,  | '  | ;  |
    OP_LPAREN, OP_RPAREN,               // | (  | )  |    |
    OP_LBRACE, OP_RBRACE,               // | {  | }  |    |
    OP_ADD, OP_SUB,                     // | +  | -  |    |
    OP_MUL, OP_DIV,                     // | *  | /  |    |

    // Other tokens     // |-Each NF--------------------|-Example-|
    ID,                 // | letter(letter|digit)*      | c1      |
    NUM,                // | digit digit*               | 123     |
    STRING,             // | ' any character except' '  | 'hi!'   |
    NONE,               // |                            | 1c      |
    ANNO                // | { any character }          | {hi}    |
};
```

并提供相关函数获取TOKEN_TYPE，其字符串形式

```
char* getTokenName(enum TOKEN_TYPE i);
enum TOKEN_TYPE getTokenType(char *token);
```

- 以下是词法分析有关数据结构

```
typedef struct TOKEN{           // TOKEN 二元组
    enum TOKEN_TYPE type;       // 词素
    char info[SIZE_2];          // 含义
}TOKEN;

FILE* file;                     // 待分析文件的指针
TOKEN file_tokens[SIZE_1];      // 保存词法分析结果
int file_tokens_num;            // 分析的TOKEN总数

int current_row;                // 当前扫描位置（行数）
int current_col;                // 当前扫描位置（列数）
char current_word[SIZE_2];      // 当前扫描得到的单词
int current_word_ptr;           // 当前扫描单词的长度
enum TOKEN_TYPE current_type;   // 当前的预测TOKEN类型
int operator_flag = 0;          // 操作符标记

int error;                      // 词法分析错误处
```

3.3 核心函数

```
/**
 * 初始化：为所有用到的变量（@line 136- 147）赋初始值，若文件无啊打开，提示报错。
 * @param file_path
 * @return 1 if the file is opened successfully, otherwise 0.
 */
int la_initial(char file_path[]);

/**
 * 根据当前的 current_word 和 current_type 生成 Tokens 并保存在 file_tokens 中。
 */
void la_make_token();

/**
```

```
 * 输出词法编译结果：显示出错原因和出错位置（几行几列）
 * @param message 出错信息
 * @param row 出错位置（行数）
 * @param col 出错位置（列数）
 */
void la_show_error(const char* message, int row, int col);

/**
 * 在扫描新的一行时进行预处理
 */
void la_update_line();

/**
 * 根据下一个字符 c 来更新 current_word 和 current_type。
 * @param c lookahead symbol
 */
void la_update_word(char c);

/**
 * 词法分析入口：执行文件字符扫描和词法分析，在出现错误时或读完程序时终止
 */
void la_start();
```

3.4 主函数

- 用户可以输入文件地址，每次输入一个文件路径，程序读取文件内容并作语法分析，将词法分析结果直接输出。
- 核心部分代码：

```
if(la_initial(file_path)){  // 1、初始化，若成功则进入词法分析
    la_start();             // 2、执行词法分析
    if(error == 0)          // 3、若没有错误出现
        la_show_result();   // 4、则输出TOKEN序列
}
```

四、测试效果

测试 1

- 测试一段普通的TINY+程序的词法分析结果

```
char str;
int x, fact;
str:= 'sample program in TINY+ language';
read x;
if x > 0 and x < 100 then { don't do it }
    fact:=1;
    while x > 0 do
        fact:=fact*x;
        x:=x-1
    write fact
end
```

- 测试结果：如下图所示。

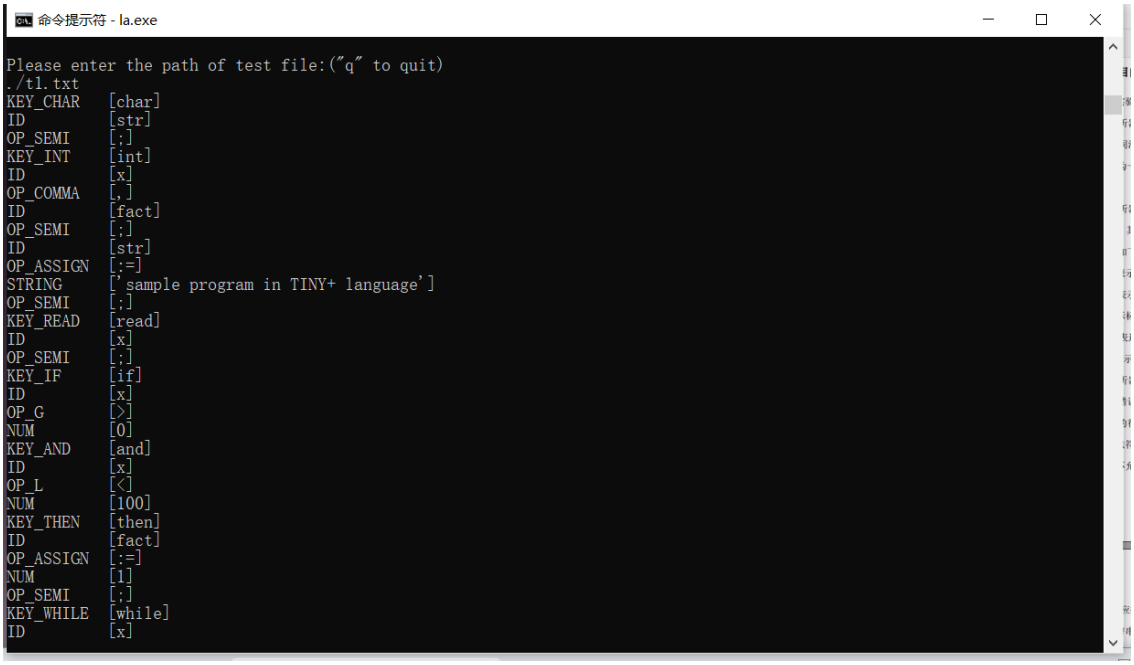

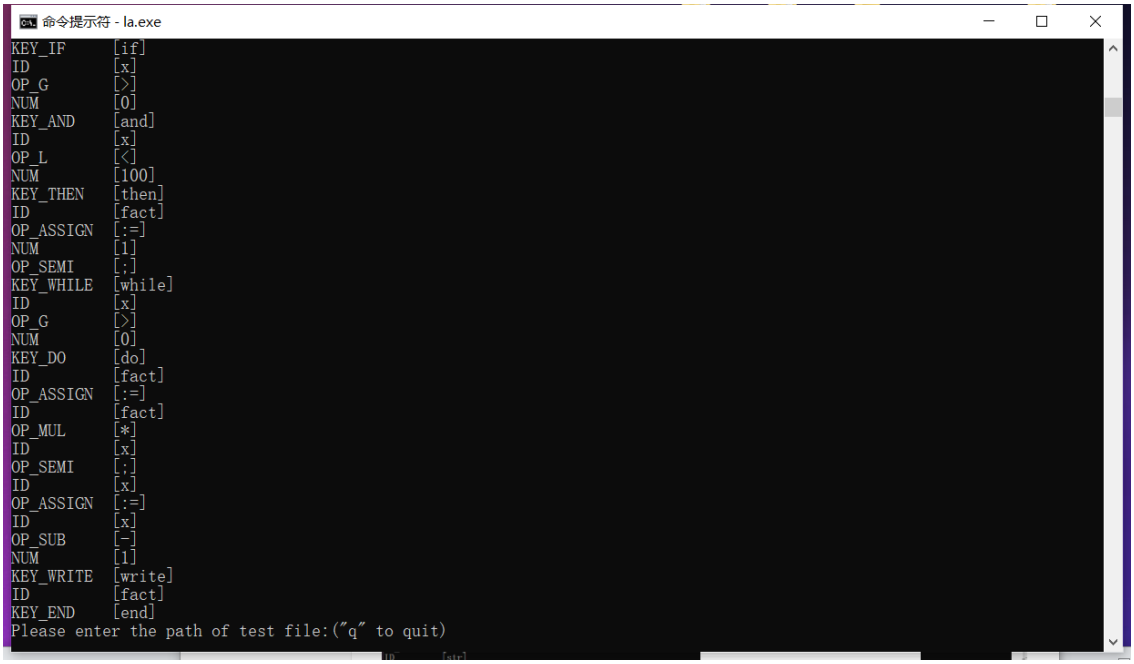

测试 2

- 测试内容：测试所有关键字和运算符，并给出几个比较特殊的嵌套例子：`{cc'oo'o}`、`'cco{}coc'`

```
true false or and not
int bool char while do
if then else end repeat
until read write , ;
:= + - * /
( ) < = >
<= >= a2c 123 'EFG'
{cc'oo'o} cco0 'cco{}coc'
```

- 测试结果：所有词都被正确识别并转化为Token

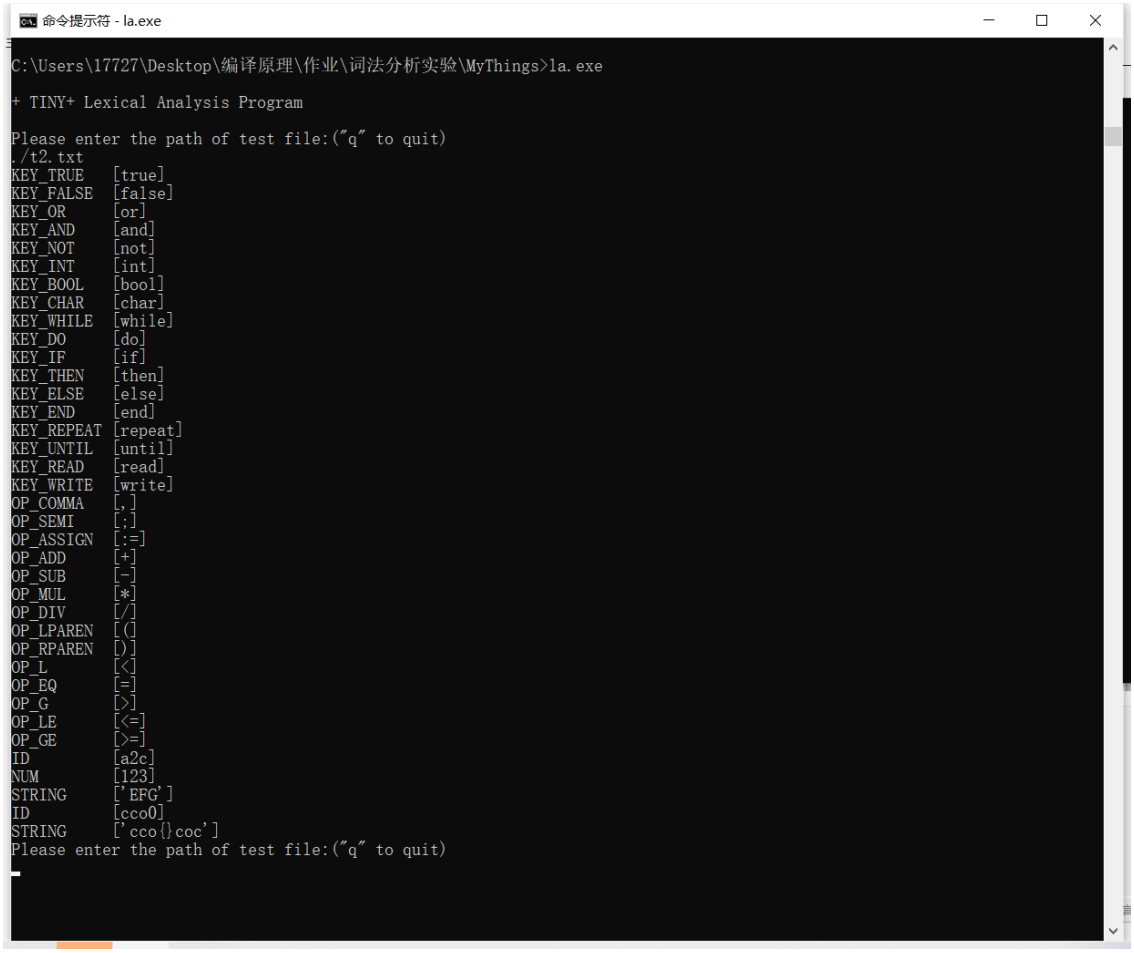

测试 3

- 测试内容：测试击中错误代码，分别保存在`t3.txt`，`t4.txt`，`t5.txt`，`t6.txt`中。

```
$ hello
123hello
hello'
hello}
```

它们分别代表：非法字符输入、非法ID、字符串不完整、注释不完整。

- 测试结果：

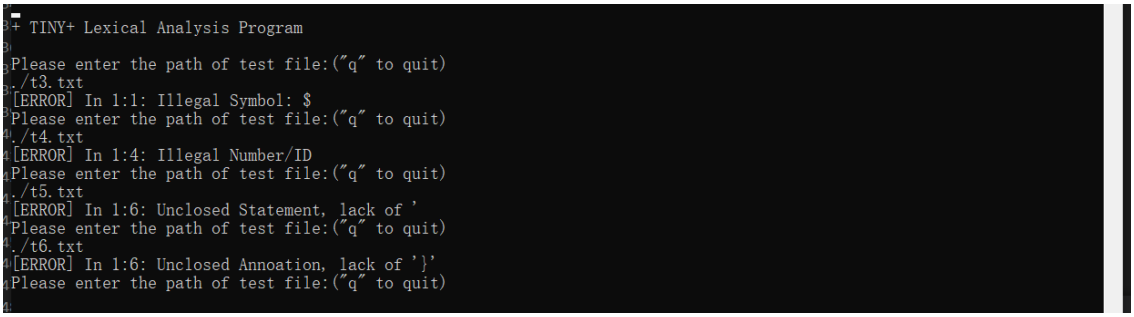

实验总结

- 本次词法分析程序实验在TINY语言的基础上进行扩充，为扩展后的TINY+语言构造词法分析程序。实验过程中充分了解了TINY及TINY词法分析器的实现，编写的程序不仅可以将TINY + 源程序翻译成对应的TOKEN序列，还能检查一定的词法错误。
- 但编写的代码比较杂乱不易于维护修改，同时，在测试上未必完善，可能还存在未发现的错误。除了直接使用C语言编写词法分析程序之外，另一种选择是使用Lex来构造词法分析程序，这种方法不

仅能确保程序的正确性，还能降低工作量。